HEARTVISION - TABELLA DI MARCIA DEL PROGETTO

Programmazione del progetto a cura di tutti i membri del gruppo: Valentina - Matteo - Giuseppe - Luca.

Organizzazione: le responsabilità indicate per ciascuna fase riguardano il coordinamento delle attività; il codice sarà condiviso, revisionato e integrato da tutti i componenti mediante la repository GitHub comune.

Obiettivo generale: sviluppare un software Python che analizzi il dataset Framingham, presenti statistiche e conclusioni sui fattori di rischio e studi un nuovo campione ricavato da questionari esterni. Un modello di Machine Learning, addestrato e verificato prima della presentazione, elaborerà il CSV delle risposte e consentirà anche di consultare un singolo partecipante tramite un ID già presente nel questionario.

FASE 1 - Creazione della struttura del programma

Responsabile della fase: Matteo

Obiettivo: Predisporre la base tecnica di HEARTVISION e il menu principale.

- Creare il file principale heartvision.py e organizzare le cartelle per dataset, questionari, modelli e risultati.
- Predisporre le librerie Python, Pandas, NumPy, Scikit-learn e Matplotlib.
- Definire le funzioni del programma e costruire il menu con quattro voci: analisi Framingham, caricamento dei questionari, analisi del campione e analisi individuale.
- Prevedere il ritorno al menu, la gestione delle scelte non valide e l'avvio automatico delle operazioni interne necessarie.

Risultato atteso: Struttura funzionante e pronta per accogliere le funzionalità sviluppate dal gruppo.

FASE 2 - Importazione e controllo del dataset Framingham

Responsabile della fase: Giuseppe

Obiettivo: Caricare il CSV HEARTVISION già aggiornato e verificarlo dietro le quinte, senza aggiungere una voce di caricamento al menu.

- Importare il DataFrame, controllare dimensioni, nomi delle colonne e tipi delle variabili.
- Verificare valori mancanti, duplicati, valori anomali e coerenza delle colonne binarie 0/1.
- Controllare i rapporti logici tra le variabili, per esempio fumatore e sigarette al giorno.
- Calcolare il BMI attraverso peso e altezza, preservando le informazioni necessarie al modello.
- Distinguere le variabili utilizzabili per le previsioni dalla colonna target relativa agli eventi coronarici entro dieci anni.

Risultato atteso: Dataset verificato, organizzato e disponibile per statistiche e addestramento. I controlli devono restare attivi anche se il CSV risulta già completo.

FASE 3 - Preparazione e addestramento del Machine Learning

Responsabile della fase: Luca

Obiettivo: Realizzare un modello in grado di elaborare i nuovi profili raccolti mediante questionario.

- Definire le feature di ingresso e la variabile target; evitare l'uso di sport e alcol sintetici come se fossero misurazioni cliniche reali.
- Suddividere i dati in training, validazione e test, mantenendo separata la valutazione finale.
- Preparare un flusso unico di preprocessing, gestione dei mancanti e scaling, evitando contaminazioni tra training e test.
- Addestrare inizialmente KNN e, se utile, confrontarlo con Decision Tree e Random Forest.
- Valutare accuracy, precision, recall, F1-score, matrice di confusione e calibrazione delle probabilità; considerare lo sbilanciamento delle classi.
- Salvare modello e trasformazioni, così da riutilizzarli quando viene caricato il CSV dei questionari.

Risultato atteso: Modello addestrato, verificato e pronto a produrre previsioni sperimentali senza essere riaddestrato a ogni avvio.

FASE 4 - Sviluppo delle quattro funzioni del menu

Responsabile della fase: Valentina

Obiettivo: realizzare l'interfaccia operativa del software, dedicata esclusivamente a statistiche, caricamento dei nuovi questionari e analisi dei risultati.

MENU 1 - Analisi statistica del dataset Framingham

- Calcolare età media, distribuzioni di sesso, fumo, diabete, ipertensione, colesterolo, BMI ed eventi coronarici.
- Confrontare le percentuali di eventi coronarici fra gruppi diversi, ad esempio soggetti con e senza precedente ictus.
- Mostrare grafici Matplotlib e brevi conclusioni generate dai valori effettivamente calcolati; distinguere le differenze percentuali dalle differenze in punti percentuali.
- Evidenziare i confronti basati su pochi soggetti, evitando conclusioni causali non dimostrate.

MENU 2 - Caricamento e pulizia del CSV dei questionari

- Chiedere il percorso del CSV esportato dal questionario esterno e verificare che contenga le colonne richieste.
- Convertire Sì/No in 0/1, controllare numeri e unità di misura e calcolare il BMI da altezza e peso.
- Individuare valori mancanti, record duplicati ed errori di inserimento; non sostituire automaticamente ogni valore elevato con la media.
- Gestire i dati impossibili secondo criteri espliciti e coerenti con il preprocessing del modello; salvare il file controllato.
- Verificare che ogni partecipante possieda già un ID univoco proveniente dal questionario, senza generarne uno nuovo in Python.

MENU 3 - Analisi del campione e previsioni

- Elaborare tutti i profili mediante il modello già salvato e riportare la classificazione prevista per ciascuno.
- Calcolare numero di partecipanti, distribuzione delle classi previste e punteggi di probabilità, se adeguatamente calibrati.
- Confrontare età, fumo, ipertensione, diabete e altri fattori tra i gruppi; presentare sport e alcol solo come dati descrittivi quando non usati dal modello.
- Creare grafici e conclusioni automatiche ricavate dal nuovo CSV; includere indicazioni generali sui comportamenti modificabili, non prescrizioni mediche.
- Salvare un CSV dei risultati che conservi l'ID originale di ogni partecipante.

MENU 4 - Analisi individuale tramite ID

- Richiedere un ID e cercarlo nel CSV dei risultati; segnalare il caso in cui non esista.
- Visualizzare le risposte del partecipante, la classe prevista e l'eventuale stima sperimentale.
- Confrontare caratteristiche individuali, come età e BMI, con le distribuzioni di Framingham e mostrare un riepilogo dei fattori presenti.
- Produrre una breve conclusione descrittiva; non presentare il risultato come diagnosi clinica.

Risultato atteso della fase 4: menu operativo con quattro scelte coerenti, ciascuna collegata alle funzioni e ai dati corretti.

FASE 5 - Creazione del Google Form e gestione degli ID

Responsabile della fase: Matteo

Obiettivo: Raccogliere i profili del campione attraverso un questionario esterno che esporti un CSV già identificato.

- Creare le domande corrispondenti alle informazioni richieste dal modello, con risposte coerenti e controlli di compilazione.
- Definire un identificativo univoco per ogni partecipante, per esempio HV-0001, e inserirlo già nel modulo.
- Poiché Google Forms non assegna da solo un codice progressivo visibile prima dell'invio, predisporre link individuali con campo ID precompilato e verificare che non siano riutilizzati o modificati.
- Distribuire i link, raccogliere le risposte e verificare che il CSV esportato conservi l'ID e tutte le colonne necessarie.
- Utilizzare profili fittizi per la dimostrazione pubblica e limitare la raccolta di dati sanitari identificabili.

Risultato atteso: Questionario operativo e CSV esportabile, con ID già assegnato a ciascun partecipante.

FASE 6 - Integrazione, test e preparazione della presentazione

Responsabile della fase: Tutti insieme: Valentina - Matteo - Giuseppe - Luca

Obiettivo: Unire le componenti sviluppate e rendere la dimostrazione fluida, chiara e riproducibile.

- Integrare e testare i moduli nella repository GitHub condivisa, coordinando commit, push e pull su main.
- Verificare il percorso completo: avvio del software, analisi Framingham, importazione CSV, previsioni sul campione e ricerca tramite ID.
- Provare CSV corretti ed errati, controllare messaggi di errore, integrità degli ID, grafici e salvataggio dei risultati.
- Concordare quali statistiche e grafici mostrare e come spiegare le conclusioni senza confondere associazioni, previsioni e cause.
- Simulare la discussione finale, dividere gli interventi e ottimizzare tempi e passaggi tra i quattro punti del menu.

Risultato atteso: HEARTVISION completo, stabile e pronto per la presentazione del progetto.

MENU DEFINITIVO

- **1.** Analisi statistica del dataset Framingham.
- **2.** Importazione e pulizia del CSV dei questionari.
- **3.** Analisi del campione e previsioni Machine Learning.
- **4.** Analisi individuale tramite ID.
- **0.** Esci dal programma.

Nota metodologica: HEARTVISION è un progetto didattico. La variabile Framingham riguarda eventi coronarici entro dieci anni. Le previsioni del software non equivalgono a una diagnosi né a una valutazione clinica validata. Le variabili sintetiche del CSV modificato non devono essere presentate come osservazioni mediche originali.