HEART VISION ♥

Software di analisi e previsione del rischio di malattia coronarica attraverso il Machine Learning

1. INTRODUZIONE AL PROGETTO

Heart Vision è un software sviluppato in Python che utilizza tecniche di Machine Learning per analizzare i dati degli utenti e stimare la probabilità di un evento coronarico nei successivi 10 anni.

Il progetto nasce con l'obiettivo di integrare il mondo delle biotecnologie e quello dell'intelligenza artificiale, sfruttando l'analisi dei dati e gli algoritmi di apprendimento automatico per individuare correlazioni tra le caratteristiche di un individuo e la presenza di fattori associati al rischio cardiovascolare.

Il sistema utilizza un dataset storico di riferimento, contenente informazioni relative a migliaia di soggetti, per addestrare diversi modelli di Machine Learning. Una volta completata la fase di addestramento e individuato il modello più adatto, il software può elaborare nuovi questionari, analizzare le caratteristiche dei singoli utenti e generare una previsione accompagnata da una percentuale associata alla classe di evento coronarico.

La previsione riguarda specificamente un possibile evento coronarico entro un periodo di 10 anni e non costituisce una diagnosi medica né una valutazione clinica individuale validata.

2. STRUTTURA E FUNZIONALITÀ DEL SOFTWARE

Il software è organizzato in diverse sezioni, ciascuna dedicata a una specifica fase del processo di analisi, dalla gestione dei dati iniziali fino alla produzione dei risultati.

2.1. Menu principale e gestione del dataset storico

Il programma dispone di un menu principale attraverso il quale è possibile richiamare le diverse funzionalità.

Una delle sezioni fondamentali permette di caricare il dataset storico, che rappresenta la base di riferimento per l'addestramento dei modelli.

Il dataset contiene informazioni relative a caratteristiche anagrafiche, abitudini di vita e condizioni di salute dei soggetti, tra cui:

- Sesso ed età.
- Abitudine al fumo e numero di sigarette giornaliere.
- Utilizzo di farmaci per la pressione.
- Precedenti episodi di ictus.
- Ipertensione, diabete e colesterolo alto.

- Peso, altezza e indice di massa corporea (BMI).
- Frequenza cardiaca.
- Consumo di alcol.
- Attività sportiva.

Il caricamento dei dati è accompagnato da una gestione delle eccezioni, pensata per intercettare eventuali problemi durante la lettura dei file, come percorsi errati, file mancanti, formati non riconosciuti o caratteri non corretti.

2.2. Pulizia e preparazione dei dati

Una fase essenziale del progetto è rappresentata dalla pulizia e dalla preparazione del dataset.

Prima di utilizzare i dati nel Machine Learning, il software esegue una serie di controlli per migliorarne la qualità e garantire una struttura coerente.

Le operazioni comprendono:

- Verifica della presenza delle colonne richieste.
- Conversione dei valori testuali in valori numerici.
- Correzione e gestione di risposte non riconosciute.
- Individuazione dei valori mancanti.
- Controllo dei valori fuori dagli intervalli plausibili.
- Gestione delle variabili binarie, come SI/NO.
- Controllo della coerenza tra le risposte, ad esempio tra abitudine al fumo e numero di sigarette giornaliere.
- Gestione dei dati mancanti attraverso valori di riferimento statistici.
- Calcolo automatico del BMI a partire da peso e altezza.

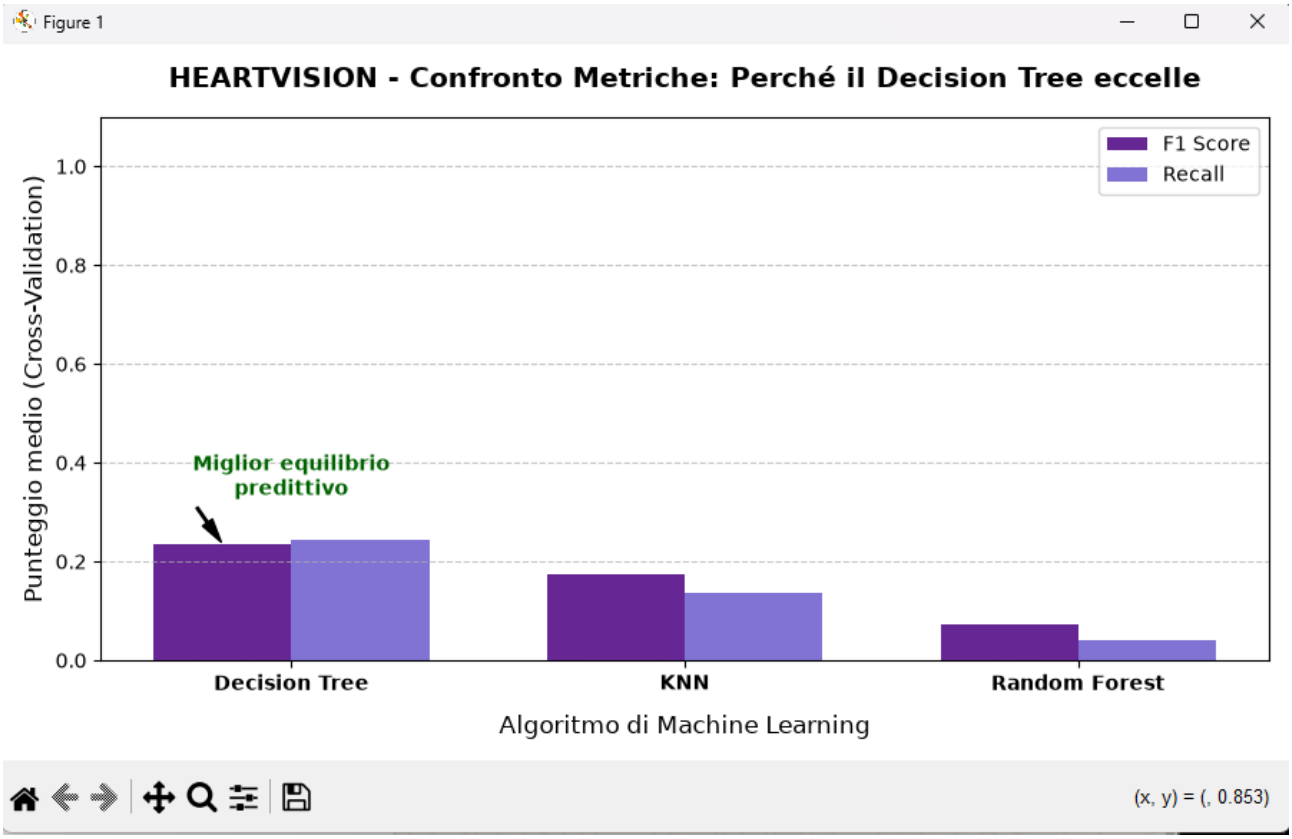
Questa fase, comunemente definita *Data Cleaning e Data Preprocessing*, è fondamentale perché la qualità dei dati influenza direttamente il comportamento degli algoritmi di Machine Learning.

2.3. Confronto tra algoritmi di Machine Learning

Una delle funzionalità centrali di Heart Vision è il confronto tra tre differenti algoritmi di apprendimento automatico:

- **K-Nearest Neighbors (KNN):** algoritmo basato sulla vicinanza tra i dati. Analizza i soggetti storici più simili a quello da classificare e utilizza le loro caratteristiche per formulare una previsione. Richiede una normalizzazione delle variabili numeriche per rendere confrontabili le diverse scale.

- **Decision Tree Classifier:** algoritmo che costruisce un albero decisionale attraverso una serie di condizioni e suddivisioni dei dati. Il risultato è un modello interpretabile, che permette di comprendere quali caratteristiche contribuiscono alle decisioni.
- **Random Forest Classifier:** algoritmo che combina più alberi decisionali, addestrati su campioni e caratteristiche differenti, per ottenere una classificazione basata sull'insieme delle loro previsioni.



Per individuare la configurazione più efficace, il software prova differenti parametri per ciascun algoritmo, confrontando le prestazioni ottenute.

La valutazione viene eseguita attraverso la tecnica della **Cross-Validation Stratificata a 5 fold**: il dataset storico viene suddiviso in cinque parti, in modo da effettuare più cicli di addestramento e validazione, mantenendo una distribuzione delle classi quanto più possibile equilibrata.

Durante questa fase vengono analizzate diverse metriche:

- **Accuracy:** percentuale complessiva di classificazioni corrette.
- **Precision:** misura quanto siano affidabili le previsioni positive.
- **Recall:** misura quanti degli eventi positivi presenti nei dati vengono individuati dal modello.
- **F1-Score:** rappresenta un equilibrio tra Precision e Recall.
- **ROC-AUC:** misura la capacità del modello di distinguere tra le due classi.

L'analisi congiunta di queste metriche permette di valutare i modelli da diversi punti di vista, evitando di basare la scelta esclusivamente sulla percentuale di classificazioni corrette.

2.4. Visualizzazione e confronto dei risultati

Terminata la fase di valutazione, Heart Vision organizza i risultati in tabelle e grafici, rendendo più semplice il confronto tra i diversi algoritmi e le relative configurazioni.

Il software permette di osservare:

- Le prestazioni medie ottenute dai modelli durante la Cross-Validation.
- Le differenze tra le varie configurazioni dei parametri.
- L'andamento dell'F1-Score e delle altre metriche.
- Il confronto tra KNN, Decision Tree e Random Forest.
- Le prestazioni delle migliori configurazioni individuate per ciascun algoritmo.

La rappresentazione grafica consente di interpretare più facilmente i risultati e di individuare il modello che offre il miglior compromesso per il problema affrontato.

2.5. Addestramento del modello e previsione sui questionari

Dopo aver confrontato gli algoritmi, il software permette di selezionare il modello desiderato e di procedere al suo addestramento definitivo.

Il modello selezionato viene addestrato utilizzando l'intero dataset storico disponibile, dopo aver individuato i parametri migliori durante la fase di confronto.

Successivamente, il programma può caricare un nuovo dataset contenente i questionari compilati dagli utenti.

I questionari vengono sottoposti alle stesse operazioni di conversione, controllo e preparazione dei dati previste per il dataset storico.

Una volta completata questa fase, le informazioni vengono fornite al modello addestrato, che elabora ciascun soggetto e restituisce:

- La classe prevista dal modello.
- La probabilità associata alla classe negativa.
- La probabilità associata alla classe positiva.
- La percentuale associata alla previsione di evento coronarico entro 10 anni.

In questo modo è possibile elaborare contemporaneamente più questionari, ottenendo una previsione individuale per ogni soggetto.

2.6. Visualizzazione dei grafici

Heart Vision integra strumenti di visualizzazione attraverso le librerie Python dedicate all'analisi dei dati, in particolare Matplotlib.

I grafici permettono di rappresentare in maniera intuitiva le informazioni elaborate dal programma, facilitando la lettura dei risultati.

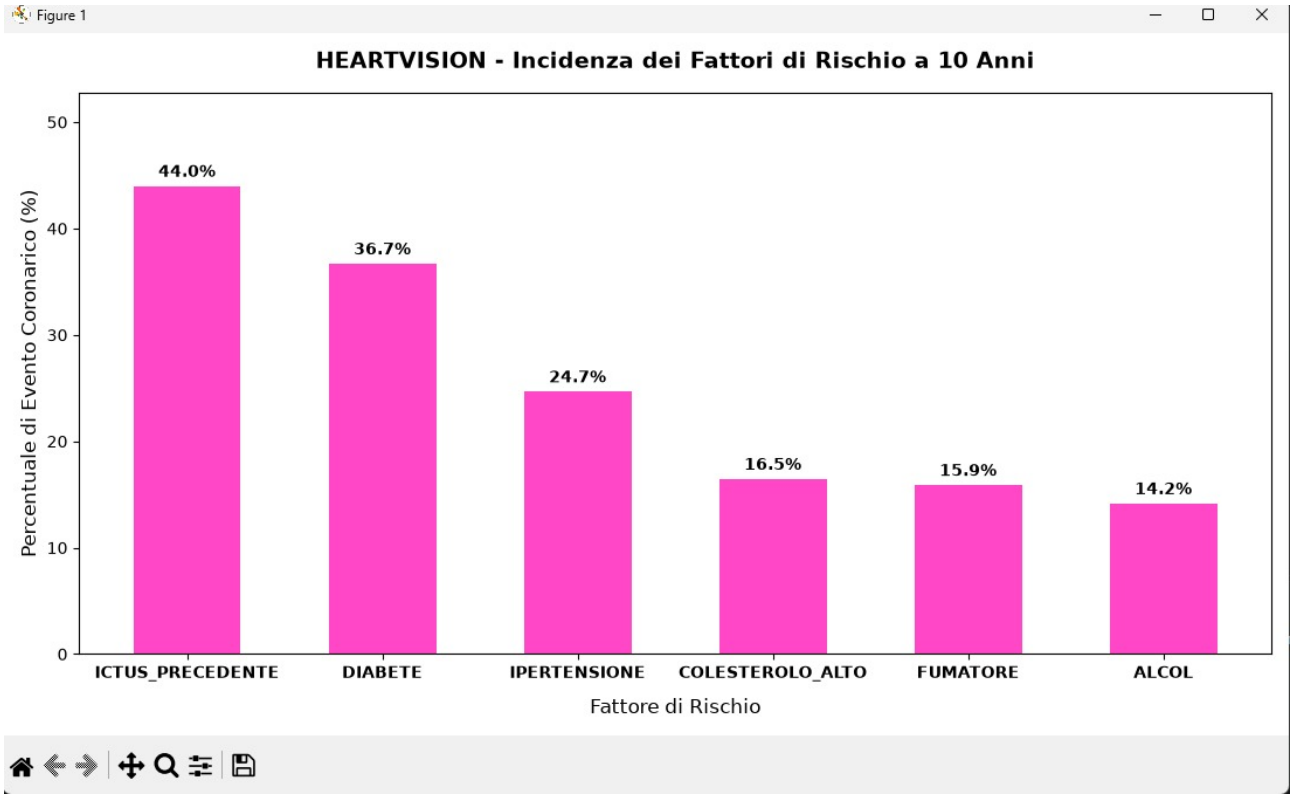
È possibile visualizzare il confronto tra gli algoritmi, le metriche di valutazione e le prestazioni delle diverse configurazioni, oltre ai risultati delle previsioni.

Questa componente rende il software non soltanto uno strumento di elaborazione, ma anche un sistema di analisi e interpretazione dei dati.

2.7. Presentazione dei risultati delle previsioni

Al termine dell'elaborazione, il programma presenta una tabella riepilogativa contenente i risultati ottenuti per ciascun utente.

Per ogni soggetto vengono riportate le informazioni principali e la relativa previsione, in modo da rendere immediatamente consultabile il risultato dell'analisi.



La percentuale restituita da `predict_proba` rappresenta la probabilità stimata dal classificatore di appartenere alla classe positiva del dataset storico. Non deve essere interpretata automaticamente come una percentuale clinicamente calibrata del rischio individuale reale.

3. TECNOLOGIE UTILIZZATE

Il progetto è stato sviluppato utilizzando Python e alcune delle principali librerie dell'ecosistema dedicato alla Data Science e al Machine Learning.

- **Python:** linguaggio principale utilizzato per lo sviluppo del software.
- **Pandas:** caricamento, gestione, manipolazione e pulizia dei dataset.
- **NumPy:** operazioni numeriche e gestione dei dati.
- **Matplotlib:** realizzazione dei grafici e visualizzazione dei risultati.
- **Scikit-learn:** implementazione degli algoritmi di Machine Learning, normalizzazione, Cross-Validation, classificazione e valutazione delle prestazioni.

L'utilizzo di queste librerie permette di realizzare un sistema modulare, organizzato e facilmente estendibile.

4. SVILUPPI FUTURI E IMPLEMENTAZIONI

Heart Vision è stato progettato con una struttura che permette di introdurre nuove funzionalità e migliorare progressivamente l'esperienza di utilizzo.

Tra gli sviluppi futuri più interessanti troviamo:

4.1. Realizzazione di un'interfaccia grafica

Una possibile evoluzione consiste nella realizzazione di un'interfaccia grafica intuitiva, che permetta di utilizzare tutte le funzionalità del software senza dover interagire direttamente con il codice Python.

L'utente potrebbe caricare i dataset attraverso appositi pulsanti, selezionare il modello di Machine Learning, avviare l'analisi e consultare i risultati attraverso schermate dedicate.

L'interfaccia potrebbe inoltre prevedere una sezione specifica per l'inserimento manuale dei dati di un singolo utente, oltre alla possibilità di importare questionari compilati da più soggetti.

4.2. Introduzione di grafici dinamici e interattivi

Un ulteriore sviluppo riguarda l'integrazione di grafici dinamici, che consentano di esplorare i risultati in maniera interattiva.

Ad esempio, potrebbe essere realizzata una dashboard nella quale selezionare un singolo utente e visualizzare immediatamente:

- La sua percentuale di previsione positiva.
- Le principali caratteristiche del suo profilo.
- Il confronto tra le sue caratteristiche e quelle dei soggetti presenti nel dataset storico.
- La distribuzione delle previsioni tra tutti gli utenti analizzati.

- Grafici comparativi aggiornati automaticamente in base ai dati selezionati.

L'obiettivo sarebbe trasformare i risultati numerici in informazioni visive più immediate e comprensibili.

4.3. Espansione del sistema di analisi

In prospettiva, il progetto potrebbe essere ampliato attraverso l'utilizzo di dataset più estesi e aggiornati, l'introduzione di ulteriori algoritmi e lo sviluppo di strumenti per interpretare meglio le decisioni del modello.

Un'altra possibilità sarebbe quella di integrare fonti di dati clinici differenti, mantenendo una particolare attenzione alla qualità, alla provenienza e alla corretta gestione delle informazioni.

Questi sviluppi richiederebbero una validazione scientifica e clinica specifica prima di qualsiasi eventuale utilizzo in ambito sanitario.

5. CONCLUSIONI

Heart Vision rappresenta un progetto che unisce programmazione, analisi dei dati, biotecnologie e Machine Learning, con l'obiettivo di esplorare le potenzialità dell'intelligenza artificiale nell'analisi dei fattori associati alle malattie cardiovascolari.

Il software non si limita ad applicare un singolo algoritmo, ma implementa un processo completo che parte dall'acquisizione e dalla pulizia dei dati, prosegue con il confronto e la valutazione di differenti modelli di Machine Learning e termina con l'elaborazione e la visualizzazione delle previsioni.

L'aspetto più importante del progetto è proprio l'integrazione di tutte queste fasi in un unico sistema, organizzato per essere progressivamente migliorato e ampliato.

Heart Vision costituisce quindi una base concreta per approfondire l'applicazione dell'intelligenza artificiale alle biotecnologie mediche, dimostrando come strumenti di programmazione e apprendimento automatico possano essere utilizzati per analizzare grandi quantità di informazioni e individuare pattern potenzialmente rilevanti per la ricerca cardiovascolare.